

Interpretable Image-Based Deep Learning for Price Trend Prediction in ETF Markets

김나영

Interpretable Image-Based Deep Learning for Price Trend Prediction in ETF Markets

- 발표 연도 : 2023.10.13
- 인용수 : 0회
- 저널명 : The European Journal of Finance

Ruixun Zhang

(교신저자) Peking University,
School of Mathematical Sciences

Chaoyi Zhao

(논문 작성 당시) Ph.D. Student in Peking University,
School of Mathematical Sciences

(현재) Postdoctoral Associate,
MIT Sloan School of Management

Dacheng Xiu

Nankai University,
College of Computer Science

Keywords

- **Price trend prediction**
- **Convolutional neural network (CNN)**
- **Attention**
- **Image**
- **Interpretability**

Index

1. **Introduction**
2. **Image Construction**
 - 1) **Augmented Candlestick Charts**
 - 2) **Gramian Angular Field (GAF) for OHLCV**
: Time-series data → Image data 로 변환
3. **Channel and Spatial CNN (CS-ACNN)**
4. **Experiment**
: 실험 및 결과
5. **Model Interpretability**
: CNN 결과 해석
6. **Economic and Financial Implications**
7. **Conclusion**

1. Introduction

연구 동기

- 최근 기계 학습, 특히 딥러닝이 자산 가격 예측, 파생상품 가격 책정, 변동성 예측 등 다양한 금융 문제에 성공적으로 사용되고 있음
 - 대부분의 연구가 시계열 데이터를 입력으로 사용하여 금융 데이터의 복잡한 관계 구조를 충분히 모델링하지 못함
- 딥러닝이 이미지에서 공간 정보를 추출한다는 점에 주목
 - 기존 연구(Jiang, Kelly, and Xiu, 2022)에서 단순한 컨볼루션 신경망(CNN)을 사용하여 캔들스틱 차트를 통해 주식 트렌드를 예측하는 방법이 수익 창출에 효과적임을 보임
 - 시계열 데이터를 이미지로 변환하는 접근법이 가능하다고 판단

1. Introduction

제안

- (1) 금융 시계열 데이터를 이미지로 변환하는 방법
 - 캔들스틱 차트의 데이터를 증강하여 정보 손실 없이 이미지를 생성하는 방법
 - 금융 시계열 데이터를 Gramian Angular Field (GAF) 방식으로 변환하여 시계열 데이터를 이미지로 표현하는 방법
- (2) 채널 (Channel) 및 공간 (Spatial) Attention 메커니즘을 활용한 딥러닝 모델 (CS-ACNN) 개발
 - 채널 차원과 공간 차원에 따라 가중치를 적용해서, 이미지에서 주가 예측과 관련된 부분에 집중함.

1. Introduction

Figure 1 : 논문에서 제안하는 프레임워크

- Label
 - 0: 다음 날 주가 “하락” 예측
 - 1: 다음 날 주가 “상승” 예측
- Image Construction
 - Left: GAF Field 적용
 - Right: Candlestick 이미지에 Augmentation 적용

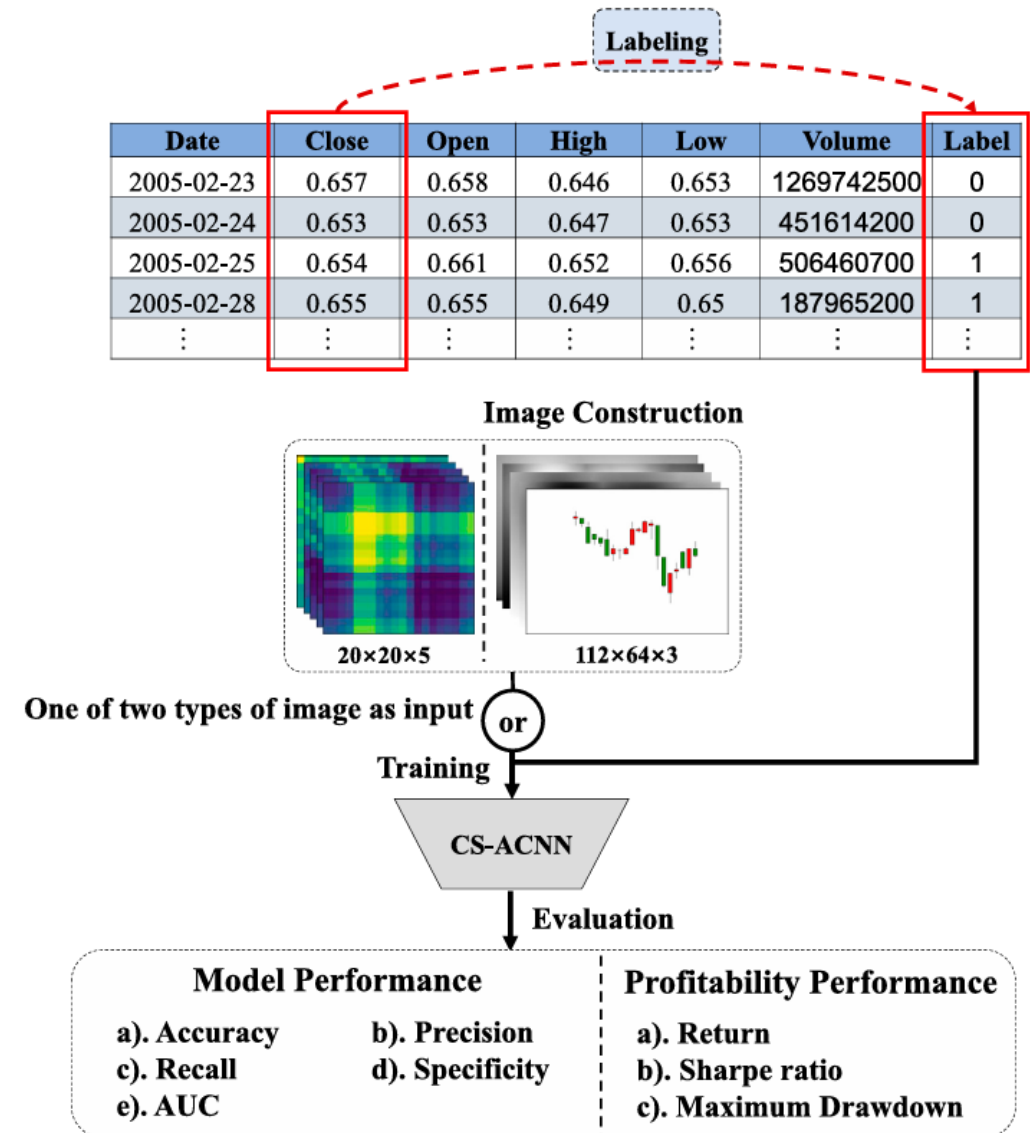


Figure 1. Illustration of our framework for price trend prediction based on images.

2. Image Construction : Time-series data → Image data 로 변환

- 금융 시계열 데이터를 이미지로 변환하는 방법
 - (1) 캔들스틱 차트의 데이터를 증강하여 정보 손실 없이 이미지를 생성하는 방법
 - (2) 금융 시계열 데이터를 Gramian Angular Field (GAF) 방식으로 변환하는 방법

2. Image Construction : Time-series data → Image data 로 변환

(1) Augmented Candlestick Charts





Figure 2. Illustration of a candlestick chart. (a) Examples of candlesticks representing downward and upward price movements, respectively. (b) A sample candlestick chart for 20 days.

Figure 2. 일반 캔들스틱 이미지

2. Image Construction : Time-series data → Image data 로 변환

(1) Augmented Candlestick Charts

- (1) 캔들스틱 차트를 흑백 이진 이미지로 변환하여, 상승 캔들은 흰색, 하락 캔들은 검은색으로 표현
- (2) 이미지 거리 변환 알고리즘을 사용하여 각 캔들스틱의 중심부와 가장자리 특징을 강화하거나 약화시키는 네 가지 추가 이미지를 생성
 - 생성된 이미지들은 원본 이미지와 함께 모델 학습에 사용되어, 각 샘플은 다섯 개의 이미지로 확장됨
 - 테스트 시에는 원본 이미지만 사용

Figure 4. 증강된 캔들스틱 이미지

- (a) 원본 캔들스틱 이미지
- (b) 강화된 캔들스틱 중심
- (c) 약화된 캔들스틱 중심
- (d) 강화된 캔들스틱 가장자리
- (e) 약화된 캔들스틱 가장자리




Figure 4. Examples of augmented candlestick charts using the image transformation algorithm. (a) Original candlestick chart. (b) Enhanced candlestick center. (c) Weakened candlestick center. (d) Enhanced candlestick edges. (e) Weakened candlestick edges.

2. Image Construction : Time-series data → Image data 로 변환

(1) Augmented Candlestick Charts

$$d(p) = \begin{cases} \min_{p_f \in I_f} \text{dis}(p, p_f), & \text{if } p \notin I_f, \\ 0, & \text{if } p \in I_f, \end{cases}$$

- (1) 캔들스틱 이미지의 모든 픽셀들 중에서 특정 픽셀 p 와 가장 가까운 전경(캔들스틱) 픽셀 p_f 간의 최소 거리 계산
 - I_f 는 전경(캔들스틱) 픽셀들의 집합
 - $\text{dis}(p, p_f)$ 는 픽셀 p 와 p_f 간의 유클리드 거리
 - p 가 전경 픽셀이 아닌 경우, p 와 가장 가까운 전경 픽셀 간의 거리 계산
 - p 가 전경 픽셀인 경우, $d(p)=0$



2. Image Construction : Time-series data → Image data 로 변환

(1) Augmented Candlestick Charts

$$p' = \frac{\sqrt{d(p)} - \min(\sqrt{d(p)})}{\max(\sqrt{d(p)}) - \min(\sqrt{d(p)})} \in [0, 1].$$

- (2) 거리 변환 값 $d(p)$ 를 정규화하여 0과 1 사이의 값으로 변환
 - $\min(d(p))$: 이미지 내 모든 픽셀의 거리 변환 값의 제곱근 중 최소값
 - $\max(d(p))$: 이미지 내 모든 픽셀의 거리 변환 값의 제곱근 중 최대값

2. Image Construction : Time-series data → Image data 로 변환

(1) Augmented Candlestick Charts

$$C_b = v(p) \times p' \times S_b(p'),$$

$$C'_b = v(p) - C_b,$$

$$C_e = v(p) \times p' \times S_e(p'),$$

$$C'_e = v(p) - C_e,$$

- (3) 중심부와 가장자리 강조/약화
 - C_b : 중심부가 강조된 캔들스틱
 - C'_b : 중심부가 약화된 캔들스틱
 - C_e : 가장자리가 강조된 캔들스틱
 - C'_e : 가장자리가 약화된 캔들스틱

$$S_b(p') = \frac{1}{1 + e^{-2\alpha p' + \alpha}},$$

$$S_e(p') = S_b^{-1}(p'),$$

- $S_b(p')$: 중심부를 강조하는 스무딩 함수
- $S_e(p')$: 가장자리를 강조하는 스무딩 함수
 - ($S_b(p')$ 의 역함수)
- $v(p)$: 원본 이진 이미지의 픽셀 값
- p' : 정규화된 거리 변환 값
 - 중심부에 가까울수록 큰 값

2. Image Construction : Time-series data → Image data 로 변환

출처: 이미지화 알고리즘 및 딥러닝을 이용한 자동 변조 분류, 한국전자파학회

(2) Gramian Angular Field (GAF) FOR OHLCV

- GAF 알고리즘이란?
 - 각 시점 간의 시간적 상관관계를 (직교 좌표계가 아닌) 극좌표를 기반으로 표현하는 알고리즘
- 장점?
 - (1) Bijective (전단사, 일대일대응) 의 특징이 있어서, 변환 과정에서 정보 손실이 없음을 보장
 - (2) 극좌표 기반 행렬은 시계열 데이터를 이미지로 변경할 때 시간 상관관계를 보존할 수 있음
 - GAF 이미지는 시계열 데이터의 각 시점 간의 관계를 2D 매트릭스로 인코딩하므로, 매트릭스의 각 요소는 두 시점 간의 관계를 나타냄 (시계열의 전체적인 시간적 패턴 보존 가능)




Figure 5. An example of Gramian Angular Field (GAF) images constructed from the opening price, high price, low price, closing price, and volume (OHLCV) of an asset with $T = 20$. (a) Opening price (b) Closing price (c) High price (d) Low price (e) Volume.

Figure 5. 시계열 데이터를 Gramian Angular Field (GAF) 방식으로 변환한 이미지

2. Image Construction : Time-series data → Image data 로 변환

(2) Gramian Angular Field (GAF) FOR OHLCV

$$\tilde{x}_t = \frac{x_t - \min(X)}{\max(X) - \min(X)},$$

- (1) 시계열 데이터 재스케일링
 - 원본 시계열 $X=(x_1, x_2, \dots, x_T)$ 를 $[0, 1]$ 범위로 재스케일링하여 \tilde{X} 를 생성

$$\begin{cases} \phi_t = \arccos(\tilde{x}_t), & \tilde{x}_t \in [0, 1], \\ u_t = \frac{t}{T}, & t \in \{1, 2, \dots, T\}. \end{cases}$$

- (2) 극좌표계로 변환
 - 재스케일된 시계열 데이터를 각도 ϕ_t 와 반지름 u_t 를 사용하여 극좌표계로 변환
 - 시계열 데이터 값은 각도, 타임스탬프 값은 반지름으로 인코딩

2. Image Construction : Time-series data → Image data 로 변환

(2) Gramian Angular Field (GAF) FOR OHLCV

$$G = \begin{bmatrix} \cos(\phi_1 + \phi_1) & \cdots & \cos(\phi_1 + \phi_T) \\ \cos(\phi_2 + \phi_1) & \cdots & \cos(\phi_2 + \phi_T) \\ \vdots & \ddots & \vdots \\ \cos(\phi_T + \phi_1) & \cdots & \cos(\phi_T + \phi_T) \end{bmatrix} = \tilde{X} \cdot \tilde{X}' - \sqrt{I - \tilde{X}^2} \cdot \sqrt{I - \tilde{X}^2}',$$

- (3) GAF 이미지 생성
 - 각도 간의 코사인 합을 통해 이미지를 생성
 - i와 j는 시계열의 두 다른 시점을 의미
 - G의 각 요소 $G_{i,j}$ 는 시계열의 두 시점 x_i 와 x_j 간의 관계를 반영

3. Channel and Spatial CNN (CS-ACNN)

(1) Network Structure

- Baseline: VggNet
 - Simonyan and Zisserman, 2014
 - 원래 VggNet 구조는 “Convolution layer -> Convolution layer -> Pooling layer” 이지만,
 - 금융 데이터의 경우 신호 대 잡음비 (Signal-to-noise)가 낮으므로*, 과적합을 방지하기 위해 “Convolution layer -> Pooling layer” 의 간단한 구조 채택
- 금융 데이터의 신호 대 잡음비 (Signal-to-noise)가 낮다?
 - 금융 시계열 데이터는 신호 (ex. 패턴) 보다 잡음 (ex. 무작위적이고 예측할 수 없는 요소) 이 포함된 경우가 많음
 - 모델이 학습할 때 불필요한 패턴을 학습하여 과적합의 위험이 높아질 수 있음

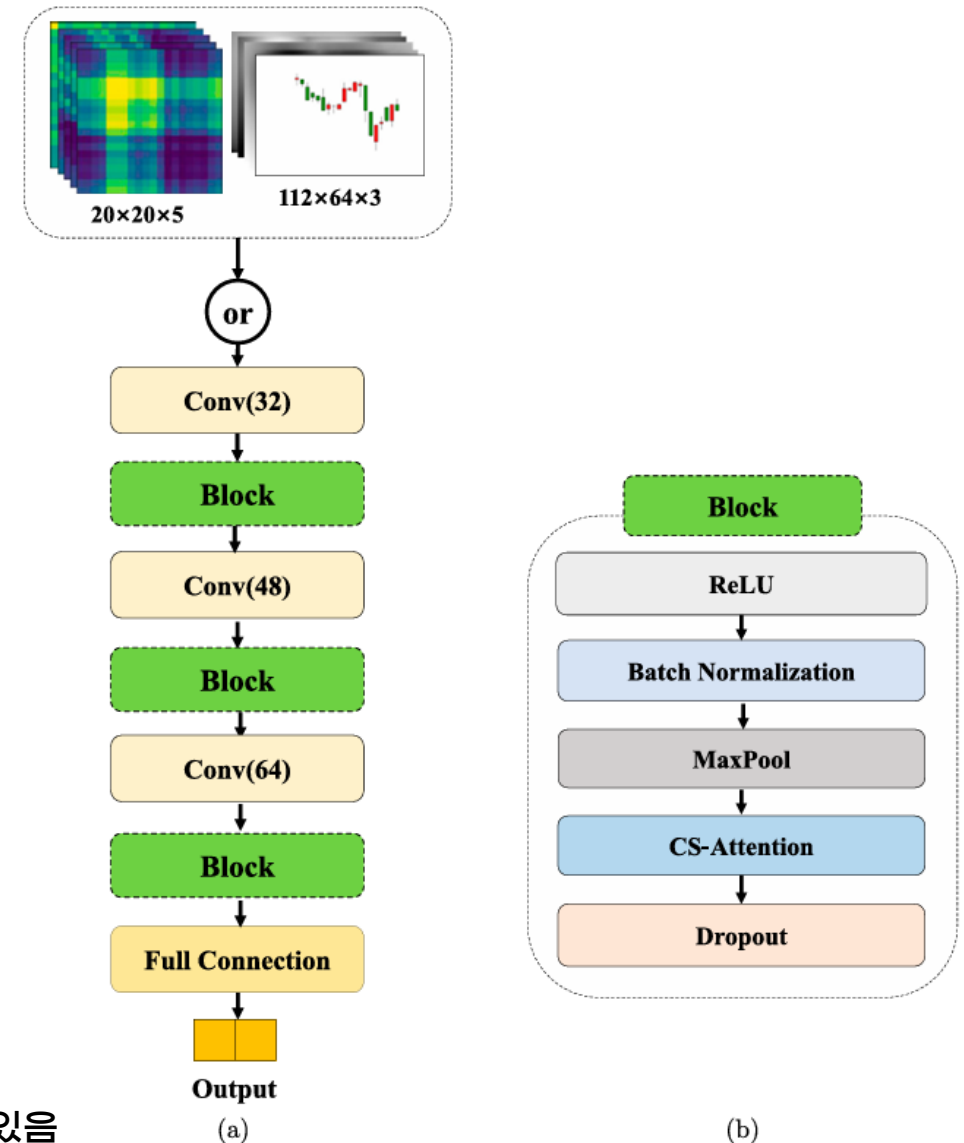


Figure 6. Network structure of CS-ACNN model. (a) Overall structure. (b) Structure for each block.

3. Channel and Spatial CNN (CS-ACNN)

(1) Network Structure

- Batch Normalization
 - 신경망의 수렴
- Dropout
 - 과적합 방지
- Softmax
 - 다음 날 주가 상승/하락 확률 계산

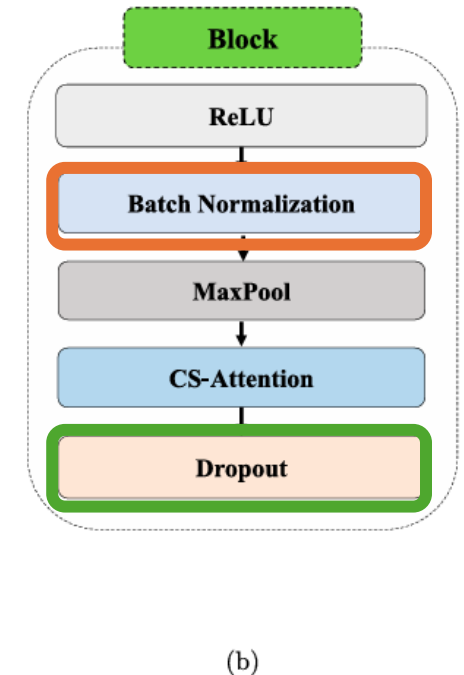
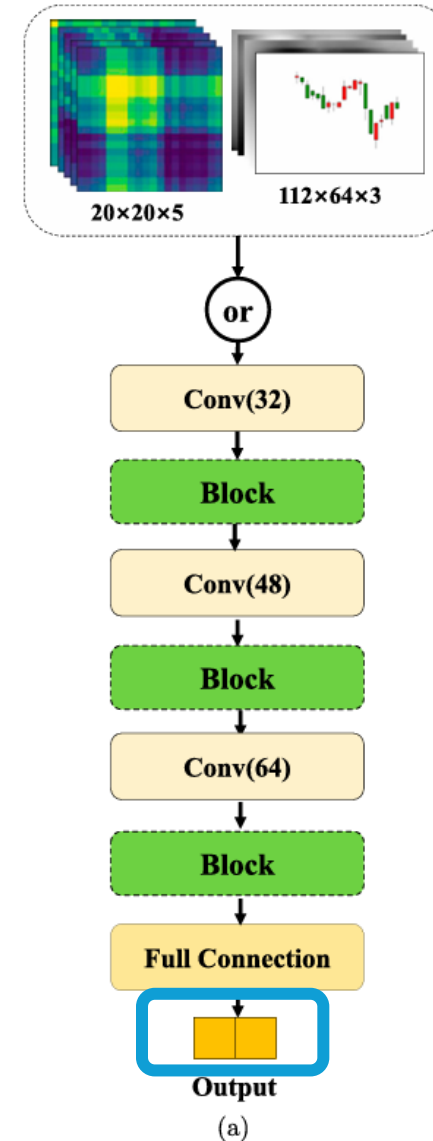


Figure 6. Network structure of CS-ACNN model. (a) Overall structure. (b) Structure for each block.

3. Channel and Spatial CNN (CS-ACNN)

(1) Network Structure

$$r_t = \frac{z_t - z_{t-1}}{z_{t-1}},$$

$$y_t = \begin{cases} 1, & r_{t+1} \geq 0, \\ 0, & r_{t+1} < 0, \end{cases}$$

- (1) 수익률 부호 예측
 - CS-ACNN 은 이미지를 입력으로 받아 이전 20 거래일의 정보를 바탕으로 다음 날의 일일 수익률 부호를 예측
 - r_t : t 일의 수익률
 - z_t : t 일의 종가
 - z_{t-1} : $t-1$ 일의 종가
 - 종가가 상승했으면 수익률 r_t 는 양수
 - 종가가 하락했으면 수익률 r_t 는 음수
- (2) 이진 레이블
 - y_t : t 일에서 $t+1$ 일 사이의 주가 움직임 방향을 나타내는 이진 레이블
 - r_{t+1} : $t+1$ 일의 수익률
 - $y_t=1$: $t+1$ 일의 수익률이 0 이상일 경우, 주가가 상승할 것으로 예측됨
 - $y_t=0$: $t+1$ 일의 수익률이 0 미만일 경우, 주가가 하락할 것으로 예측됨

3. Channel and Spatial CNN (CS-ACNN)

(2) Attention Module

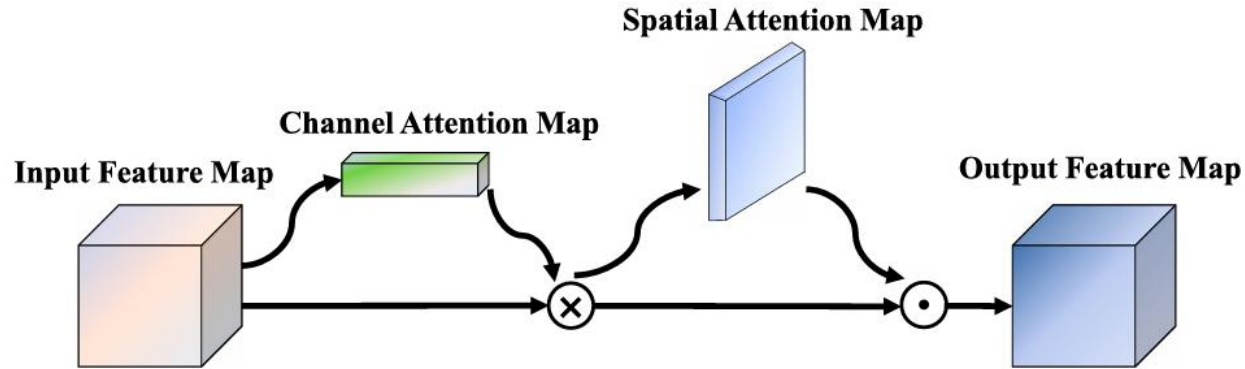


Figure 7. The overall structure of the channel and spatial attention (CS-Attention).

- 모델의 시각적 특징 (visual feature) 추출 능력을 높이고자 CS-Attention Module 제안
- 입력 피처맵 (feature map)의 차원: $H * W * C$ 라고 할 때,
 - 채널 차원 (C)를 따라 상대적 중요도를 인코딩
 - 공간 차원 ($H * W$)를 따라 상대적 중요도를 인코딩

3. Channel and Spatial CNN (CS-ACNN)

(2) Attention Module

$$A_c = \text{Sigmoid}(\text{Conv1D}(\text{AvgPool}(F)) + \text{Conv1D}(\text{MaxPool}(F))),$$

$$F_c = A_c \otimes F,$$

- (1) Channel Attention mechanism
 - 1) 평균 풀링과 맥스 풀링을 통해 각 채널의 요약 정보 추출
 - $\text{AvgPool}(F)$, $\text{MaxPool}(F)$
 - 2) Conv1D 를 통해 채널 차원에서 비선형 변환을 적용하여 각 채널의 중요도를 학습
 - $\text{Conv1D}(\text{AvgPool}(F))$, $\text{Conv1D}(\text{MaxPool}(F))$
 - 3) 두 값을 합쳐서 하나의 피쳐 벡터로 만든 후,
시그모이드 함수를 통해 각 채널의 중요도를 0과 1 사이의 값으로 정규화
 - $\text{Sigmoid}(\text{Conv1D}(\text{AvgPool}(F)) + \text{Conv1D}(\text{MaxPool}(F)))$
 - 4) Channel Attention Map (A_c) 를 Input Feature Map (F) 에 곱하여,
Channel Attention 이 적용된 피쳐 맵 (F_c) 생성

3. Channel and Spatial CNN (CS-ACNN)

(2) Attention Module

$$query = \text{reshape}(\text{Conv2D}_q(F_c), (H \times W, C)),$$

$$key = \text{reshape}(\text{Conv2D}_k(F_c), (H \times W, C)),$$

$$value = \text{reshape}(\text{Conv2D}_v(F_c), (H \times W, C)),$$

- (2) Spatial Attention mechanism

- 1) Conv2D 를 통해 로컬 패턴을 추출하고 중요한 공간적 패턴 학습

- 2) reshape는 피쳐 맵의 크기를 (x,y)로 재구성하는 연산

- 3) query, key 의 행렬 곱을 통해 Attention score 맵 (A_s) 계산

- A_s 는 각 공간 위치의 중요도를 나타내며, 이를 통해 밸류 피쳐 맵의 가중합을 계산

- A_s 의 (i, j) 요소는 i 번째 공간 위치의 특징에 대해 j 번째 공간 위치의 특징이 미치는 영향 정도

- query: 입력 피쳐 맵의 각 공간 위치에서 특징을 추출하여, 다른 위치와의 유사도를 계산

- key: 입력 피쳐 맵의 각 공간 위치에서 특징을 추출하여, query와의 유사도를 계산하는 기준

- value: 입력 피쳐 맵의 각 공간 위치에서 특징을 추출하여, 최종 출력 피쳐 맵을 생성

- 4) 최종 출력 피쳐 맵 (F_s) 의 각 요소는 모든 위치에서 피쳐의 가중 합으로 도출됨

$$A_s = \text{Softmax}(query \cdot key').$$

$$F_s = W_s \cdot (A_s \cdot value) + F,$$

3. Channel and Spatial CNN (CS-ACNN)

(2) Attention Module

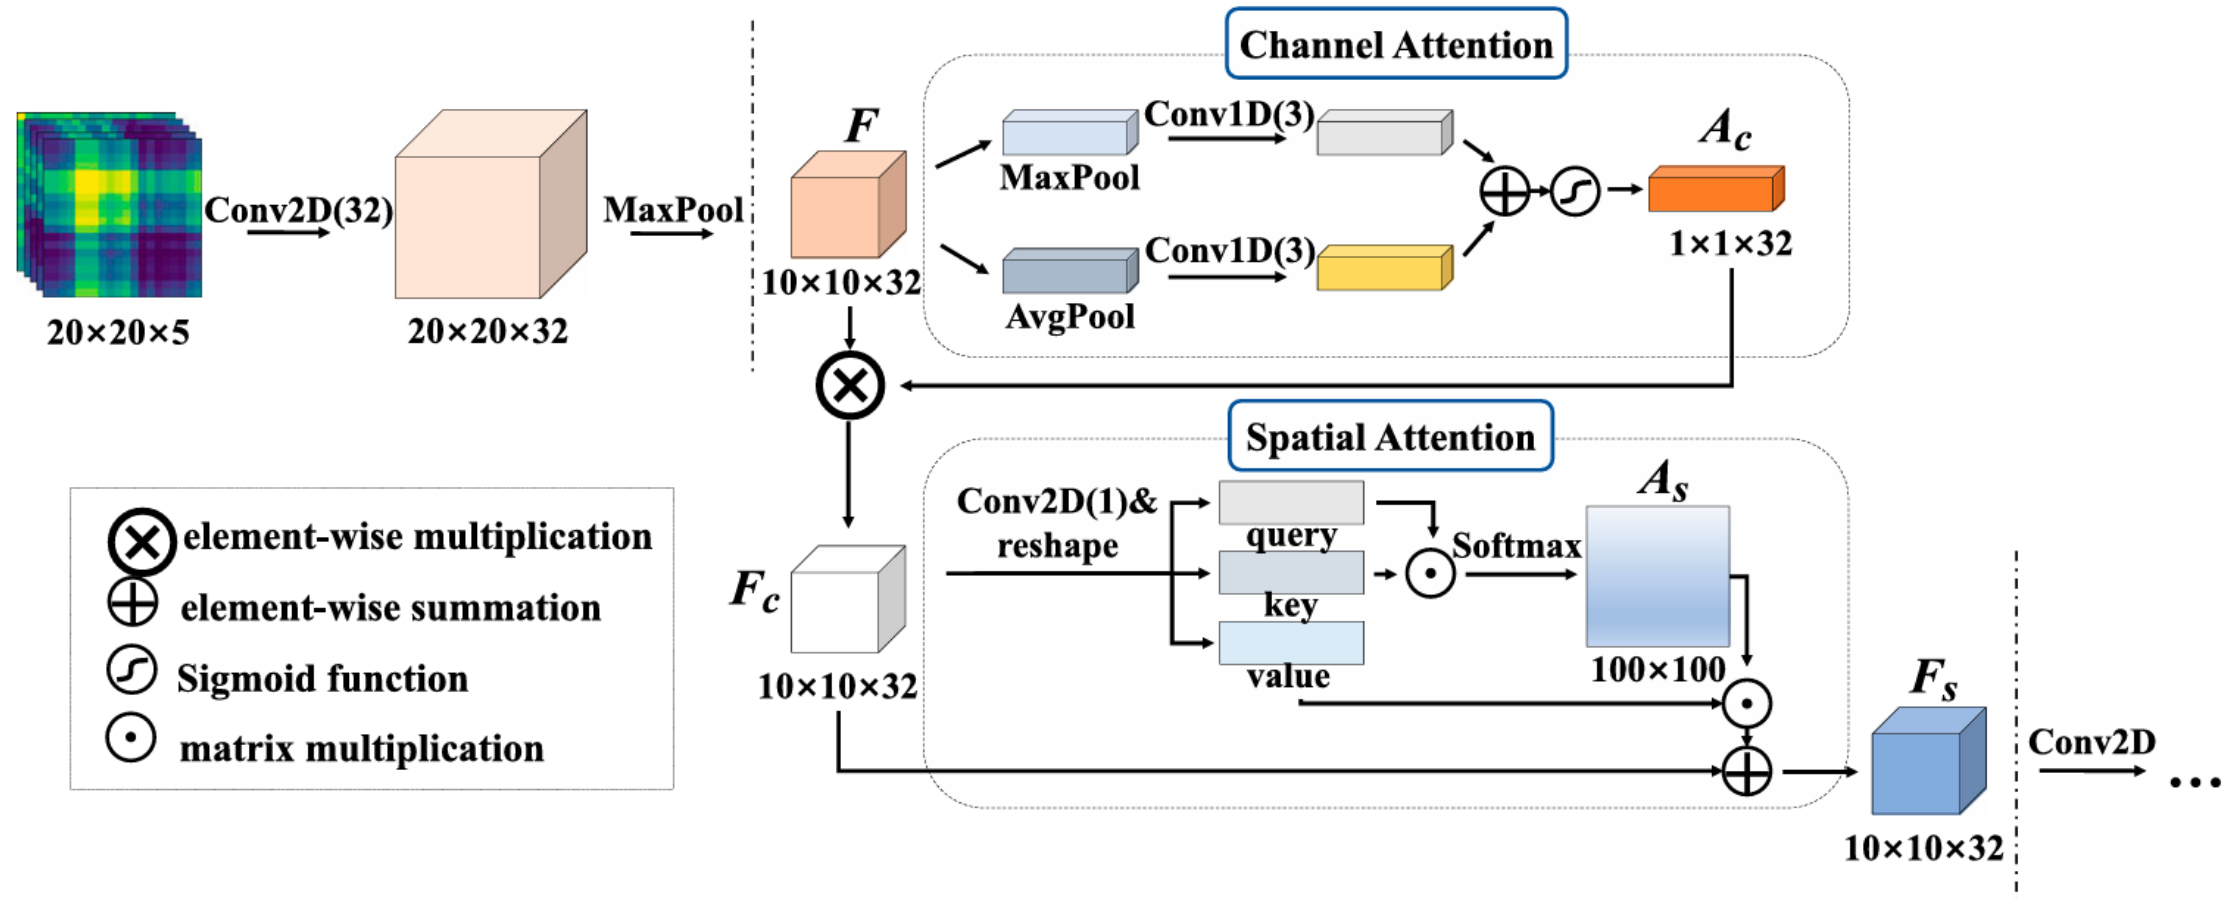


Figure 8. Implementation details of the CS-Attention module for a sample input image of dimensions $20 \times 20 \times 5$.

3. Channel and Spatial CNN (CS-ACNN)

(3) Loss Function and Model Training

- (1) Loss Function
 - 이진 분류 문제이므로 크로스 엔트로피 손실을 사용하여, 모델의 예측과 실제 레이블 간의 차이를 측정
- (2) Model Training
 - 1) Optimizer
 - 확률적 경사 하강법(Stochastic Gradient Descent), Adam
 - 2) Learning rate: 0.01 로 초기화
 - 3) Batch size: 256
 - 4) 과적합 방지
 - Dropout Layer: dropout rate 0.25 로 설정
 - Learning Rate Decay: 시간에 따라 선형적으로 학습률을 감소시켜 그래디언트의 불안정 방지
 - Early Stopping: Validation loss 가 30 epochs 연속으로 개선되지 않으면 조기 종료

4. Experiment

(1) Data

- (1) 주가 지수 ETF의 OHLCV 일별 시계열 데이터 (기간: ETF 출시일 ~ 2022년 2월 10일)
 - SPDR S&P 500 ETF (SPY): 미국 주식 (1993년 1월 29일 ~ 2022년 2월 10일)
 - Hang Seng Index ETF (2833.HK): 홍콩 주식 (2004년 9월 21일 ~ 2022년 2월 10일)
 - China AMC SSE 50 ETF (510050.SS): 중국 A주 (2005년 2월 23일 ~ 2022년 2월 10일)
- (2) 데이터 분할
 - Training : 64%
 - Validation : 16%
 - Test : 20%
- (3) 데이터 통계
 - 거래일수,
 - 연 평균 수익률 및 표준편차
 - 상승 및 하락일 수

Table 1. Summary statistics of the data. Average returns and standard deviations are annualized based on 252 trading days in a year.

Set	# Days	Ave. Return	Std. of Return	# 'Up'	# 'Down'
Panel A: SPY					
Training	4,684	9.09%	19.82%	2,485	2,199
Validation	1,171	15.21%	14.59%	645	526
Test	1,463	15.89%	18.13%	822	641
All	7,318	11.43%	18.74%	3,952	3,366
Panel B: 2833.HK					
Training	2,744	11.42%	25.08%	1,376	1,368
Validation	686	11.79%	16.60%	355	331
Test	858	1.55%	20.49%	420	438
All	4,288	9.51%	23.03%	2,151	2,137
Panel C: 510050.SS					
Training	2,642	15.58%	30.49%	1,302	1,340
Validation	660	6.04%	17.15%	333	327
Test	826	11.33%	20.97%	418	408
All	4,128	13.21%	27.02%	2,053	2,075

4. Experiment

(2) Model Performance

- 이진 분류 (상승/하락) 문제이므로 confusion matrix 으로 모델의 성능 평가
 - (1) Accuracy (정확도)
 - 모델이 올바르게 예측한 비율
 - (2) Precision (정밀도)
 - 모델이 양성 클래스로 예측한 것 중 실제로 양성인 비율
 - (3) Recall (재현율)
 - 실제 양성 클래스 중에서 모델이 올바르게 예측한 비율
 - (4) Specificity (특이도)
 - 실제 음성 클래스 중에서 모델이 올바르게 예측한 비율
 - (5) AUC (Area Under the Curve)
 - ROC 곡선 아래 면적, 모델의 분류 성능을 평가하는 지표

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN},$$

$$\text{Specificity} = \frac{TN}{TN + FP}.$$

4. Experiment

(2) Model Performance - Effectiveness of image augmentation

- (1) Original candlestick
- (2) Original candlestick
+ Enhanced candlestick center + Weakened candlestick center + Enhanced candlestick edge + Weakened candlestick edge (총합)
- (3) Original candlestick
+ Enhanced candlestick center
+ Enhanced candlestick edge (중심/가장자리 강화)
- (4) Original candlestick
+ Weakened candlestick center
+ Weakened candlestick edge (중심/가장자리 약화)
- (5) Original candlestick
+ Enhanced candlestick center
+ Weakened candlestick center (중심 강화/약화)
- (6) Original candlestick
+ Enhanced candlestick edge
+ Weakened candlestick edge (가장자리 강화/약화)

Table 2. Performance of the CS-ACNN model when different configurations of the candlestick images are used as input.

Image configuration	Accuracy	Precision	Recall	Specificity	AUC
Panel A: SPY					
(1)	0.534	0.562	0.796	0.193	0.511
(2)	0.573	0.597	0.753	0.339	0.566
(3)	0.525	0.558	0.766	0.212	0.513
(4)	0.549	0.571	0.815	0.204	0.533
(5)	0.546	0.572	0.782	0.239	0.544
(6)	0.552	0.575	0.800	0.229	0.539
Panel B: 2833.HK					
(1)	0.528	0.592	0.480	0.588	0.533
(2)	0.571	0.638	0.523	0.631	0.562
(3)	0.520	0.582	0.471	0.580	0.513
(4)	0.546	0.610	0.501	0.602	0.527
(5)	0.541	0.596	0.533	0.551	0.522
(6)	0.549	0.600	0.559	0.537	0.534
Panel C: 510050.SS					
(1)	0.523	0.542	0.566	0.475	0.521
(2)	0.566	0.593	0.545	0.590	0.557
(3)	0.518	0.538	0.557	0.475	0.515
(4)	0.542	0.556	0.611	0.465	0.528
(5)	0.545	0.560	0.607	0.478	0.540
(6)	0.548	0.564	0.592	0.499	0.522

Note: In each panel, the best performance for each metric across different configurations is highlighted in bold.

4. Experiment

(2) Model Performance - Effectiveness of images as input

- 이미지 데이터를 입력으로 사용하는 모델
 - CS-ACNN
- 시계열 데이터를 입력으로 사용하는 모델과 비교
 - SVM, LSTM, 1D-CNN
- Recall 과 Specificity 의 값이 1에 가까운 값
 - 대부분의 시계열 데이터를 단일 카테고리 ('상승' 또는 '하락')로 분류하는 경향이 있음
 - 금융 시계열과 미래 수익 간의 복잡한 관계를 제대로 포착하지 못함

Table 3. Performance comparison of GAF images and candlestick charts with time series data as input to machine learning models.

Model	Input Data	Accuracy	Precision	Recall	Specificity	AUC
Panel A: SPY						
CS-ACNN	GAF	0.567	0.591	0.764	0.312	0.547
	Candlestick	0.573	0.597	0.753	0.339	0.568
	Time Series	0.520	0.623	0.382	0.699	0.517
SVM	Time Series	0.555	0.561	0.974	0.010	0.514
LSTM	Time Series	0.529	0.684	0.310	0.814	0.522
1D-CNN	Time Series	0.501	0.673	0.229	0.855	0.507
Panel B: 2833.HK						
CS-ACNN	GAF	0.565	0.609	0.602	0.519	0.555
	Candlestick	0.571	0.638	0.523	0.631	0.551
	Time Series	0.524	0.587	0.477	0.583	0.509
SVM	Time Series	0.558	0.557	0.994	0.016	0.508
LSTM	Time Series	0.529	0.593	0.480	0.591	0.511
1D-CNN	Time Series	0.509	0.688	0.209	0.882	0.513
Panel C: 510050.SS						
CS-ACNN	GAF	0.551	0.563	0.637	0.457	0.545
	Candlestick	0.566	0.593	0.545	0.590	0.549
	Time Series	0.512	0.535	0.518	0.505	0.504
SVM	Time Series	0.501	0.529	0.410	0.600	0.487
LSTM	Time Series	0.515	0.537	0.538	0.491	0.515
1D-CNN	Time Series	0.502	0.656	0.100	0.943	0.498

Note: In each panel, the best performance for each metric across different configurations is highlighted in bold.

4. Experiment

(2) Model Performance - Effectiveness of the CS-ACNN model

- 이미지를 입력 & Attention 메커니즘 사용
- 이미지를 입력 & Attention 메커니즘 사용 X
 - SVM, CNN-TA
- SVM과 CNN-TA 모두 테스트 샘플을 단일 카테고리 분류하여 상승 및 하락 추세를 의미 있게 구분하지 못함

Table 4. Performance comparison of the CS-ACNN model against benchmark models when GAF images and candlestick charts are used as input images, respectively.

Model	Image	Accuracy	Precision	Recall	Specificity	AUC
Panel A: SPY						
CS-ACNN	GAF	0.567	0.591	0.764	0.312	0.547
	Candlestick	0.573	0.597	0.753	0.339	0.568
SVM	GAF	0.517	0.553	0.764	0.196	0.491
	Candlestick	0.565	0.565	1.000	0.000	0.500
CNN-TA	GAF	0.542	0.567	0.803	0.202	0.522
	Candlestick	0.540	0.580	0.660	0.384	0.532
Panel B: 2833.HK						
CS-ACNN	GAF	0.565	0.609	0.602	0.519	0.555
	Candlestick	0.571	0.638	0.523	0.631	0.551
SVM	GAF	0.504	0.567	0.445	0.578	0.491
	Candlestick	0.554	0.554	1.000	0.000	0.500
CNN-TA	GAF	0.524	0.591	0.460	0.604	0.522
	Candlestick	0.541	0.534	0.561	0.521	0.527
Panel C: 510050.SS						
CS-ACNN	GAF	0.551	0.563	0.637	0.457	0.545
	Candlestick	0.566	0.593	0.545	0.590	0.549
SVM	GAF	0.511	0.532	0.531	0.488	0.518
	Candlestick	0.523	0.523	1.000	0.000	0.500
CNN-TA	GAF	0.530	0.546	0.604	0.449	0.522
	Candlestick	0.523	0.528	0.514	0.533	0.526

Note: In each panel, the best performance for each metric across different configurations is highlighted in bold.

4. Experiment

(3) Profitability

- 자산 가격 추세 예측에 기반한 롱온리(long-only) 및 롱쇼트(long-short) 전략을 구현
 - 벤치마크로 사용되는 단순 매수 후 보유 (buy-and-hold) 전략과 비교
 - 자본: V
 - 거래비용: c

• (1) 롱 온리 전략

- 두 번의 연속 거래 예측이 동일하다면 거래 비용이 발생하지 않음

$$\tilde{V}_t = \begin{cases} V_{t-1}(1 + r_t), & \text{if } \hat{y}_{t-1} = 1, \\ V_{t-1}, & \text{if } \hat{y}_{t-1} = 0. \end{cases}$$

$$V_t = \begin{cases} \tilde{V}_t, & \text{if } \hat{y}_{t-1} = \hat{y}_{t-2}, \\ \tilde{V}_t(1 - c\%), & \text{if } \hat{y}_{t-1} \neq \hat{y}_{t-2}. \end{cases}$$

• (2) 롱쇼트 전략

- 새로운 포지션을 열기 전에 기존 포지션을 먼저 종료해야 하므로 거래 비용이 두 배로 발생

$$V_t = \begin{cases} \tilde{V}_t, & \text{if } \hat{y}_{t-1} = \hat{y}_{t-2}, \\ \tilde{V}_t(1 - c\%), & \text{if } \hat{y}_{t-1} \neq \hat{y}_{t-2}. \end{cases}$$

$$V_t = \begin{cases} \tilde{V}_t, & \text{if } \hat{y}_{t-1} = \hat{y}_{t-2}, \\ \tilde{V}_t(1 - 2c\%), & \text{if } \hat{y}_{t-1} \neq \hat{y}_{t-2}. \end{cases}$$

• (3) 매수 후 보유 전략

$$V_t = V_0 \cdot \frac{z_t}{z_0} \cdot (1 - c\%) = (1 - c\%) V_0 \prod_{s=1}^t (1 + r_s).$$

4. Experiment

(3) Profitability

- LSTM, 1D-CNN
 - 모델이 위험을 회피하는 결과로
높은 샤프 비율과 낮은 최대 손실폭을
달성
- 연 수익률은 CS-ACNN에 비해
낮음
- Table 3에서, 가격 움직임을 예측하지 않아서 (= 단일
카테고리로만 분류) 거래를 하지 않기 때문이며,
 - 이는 수익 잠재력이 낮기 때문에 투자자들이 선
호하지 않는 전략
- 모델이 위험을 회피하는 대신,
추세를 정확히 예측하고 이익을 발견하여 위험과 수익
을 얻는 것은 CS-ACNN이 더 효과적

Table 5. Profitability of investment strategies based on each model.

		AnnualR		SR		MDD	
Model	Input	long-only	long-short	long-only	long-short	long-only	long-short
Panel A: SPY							
CS-ACNN	Time Series	18.24%	19.94%	1.48	0.99	9.70%	28.60%
	GAF	24.14%	31.72%	1.44	1.65	20.13%	19.43%
	Candlestick	25.25%	33.95%	1.57	1.78	17.22%	17.22%
SVM	Time Series	15.38%	14.23%	0.74	0.67	34.10%	34.10%
	GAF	12.15%	7.77%	0.59	0.32	33.08%	43.21%
	Candlestick	16.53%	16.53%	0.80	0.80	34.10%	34.10%
CNN-TA	GAF	15.49%	14.45%	0.78	0.69	28.74%	28.74%
	Candlestick	15.38%	14.47%	0.77	0.73	27.13%	29.33%
LSTM	Time Series	12.00%	7.45%	1.97	0.30	8.47%	38.48%
1D-CNN	Time Series	10.72%	4.90%	1.90	0.16	3.97%	56.48%
Buy-and-hold		17.81%		0.87		34.10%	
Panel B: 2833.HK							
CS-ACNN	Time Series	10.53%	18.88%	0.58	0.83	14.65%	14.64%
	GAF	22.12%	42.05%	1.32	2.00	10.82%	11.01%
	Candlestick	26.71%	51.24%	1.75	2.46	7.13%	7.93%
SVM	Time Series	2.14%	2.14%	0.01	0.01	25.43%	25.43%
	GAF	8.50%	14.84%	0.45	0.63	16.92%	15.96%
	Candlestick	2.15%	2.15%	0.01	0.01	25.67%	25.67%
CNN-TA	GAF	12.84%	23.51%	0.76	1.06	12.63%	13.99%
	Candlestick	13.34%	17.48%	0.88	1.21	13.31%	15.59%
LSTM	Time Series	12.30%	22.42%	0.25	1.01	14.18%	14.42%
1D-CNN	Time Series	14.64%	27.12%	1.28	1.24	10.82%	23.17%
Buy-and-hold		0.27%		−0.08		25.67%	
Panel C: 510050.SS							
CS-ACNN	Time Series	10.82%	9.49%	0.55	0.36	21.31%	27.51%
	GAF	35.09%	58.00%	2.05	2.81	8.58%	10.34%
	Candlestick	37.16%	62.12%	2.52	3.03	5.97%	11.14%
SVM	Time Series	4.17%	−3.80%	0.16	−0.28	20.21%	42.17%
	GAF	17.14%	22.12%	0.91	0.98	15.02%	16.78%
	Candlestick	12.15%	12.15%	0.49	0.49	23.35%	23.35%
CNN-TA	GAF	26.09%	39.98%	1.58	1.89	9.44%	10.88%
	Candlestick	26.04%	37.73%	1.34	1.65	12.32%	17.74%
LSTM	Time Series	17.24%	22.31%	0.96	0.98	15.02%	17.29%
1D-CNN	Time Series	11.84%	11.53%	1.36	0.46	3.30%	32.33%
Buy-and-hold		13.75%		0.57		22.54%	

Note: In each panel, the best performance for each metric across different configurations is highlighted in bold.

4. Experiment

(3) Profitability

- Robustness
 - (1) SPY
 - 2020 1Q (COVID 19) 를 제외하고 대부분 강세장
 - Buy-and-hold 를 제외한 Long-only, Long-short 에서 상승 추세
 - (2) HK, SS
 - 특별히 강세장이나 약세장을 겪지 않았음
 - Long-only, Long-short 에서 안정적인 수익




Figure 9. The time series of total portfolio wealth for investment strategies based on the CS-ACNN model with candlestick charts as input. (a) SPY (b) 2833.HK (c) 510050.SS.

4. Experiment

(4) Computational Cost

Table 6. Time cost (in hours) for training the CS-ACNN model.

Image Stage	GAF		Candlestick		Train
	Construction	Train	Construction	Augmentation	
SPY	0.0033	0.39	0.31	0.48	6.32
2833.HK	0.0023	0.25	0.15	0.34	3.77
510050.SS	0.0015	0.19	0.11	0.33	3.67

- 시간이 가장 많이 소요되는 단계
 - Construction (시계열 데이터를 이미지로 변환)
 - Train (모델 학습)
 - 특히, 캔들차트의 경우, 모델 학습에 몇 시간씩 소요됨
- 일일 리밸런싱 전략은 가능하나, 고빈도 거래에서는 CS-ACNN 을 적용할 경우 계산 비용 고려해야 함

5. Model Interpretability

- 금융 프로그램에서는 모델이 학습하는 패턴을 이해하는 것이 중요
 - 모델이 실제로 경제적 직관에 부합하는 패턴을 학습하는지 확인
 - 미래에도 성과가 지속될 가능성이 있는지 진단
- 모델이 입력 이미지의 어떤 영역을 활성화하는지 시각화하기 위해 Grad-CAM 기법으로 확인
- CS-ACNN 모델이 금융 시장에서 잘 알려진 기술적 분석 패턴을 학습하는지 확인

5. Model Interpretability

(1) Visualization Methodology

- 1) 어떤 레이블 (ex. “상승” 혹은 “하락”)에 대한 마지막 컨볼루션 층의 각 채널의 가중치를 역전파 연산을 통해 계산

$$w_k^y = \underbrace{\frac{1}{Z} \sum_i \sum_j}_{\text{Global Ave. Pool.}} \underbrace{\frac{\partial w^y}{\partial F_{ij}^k}}_{\text{Backprop Grad.}}$$

- uy: 소프트맥스 연산 직전의 카테고리 y에 해당하는 값
- F: 컨볼루션으로 얻어진 피쳐 맵
- 2) 각 채널의 피쳐 맵은 선형적으로 가중치가 부여되어, 컨볼루션 피쳐 맵과 같은 크기의 히트맵을 생성
- 3) 이 히트맵에 ReLU 연산을 추가하여 카테고리 y에 긍정적인 영향을 미치는 영역을 활성화

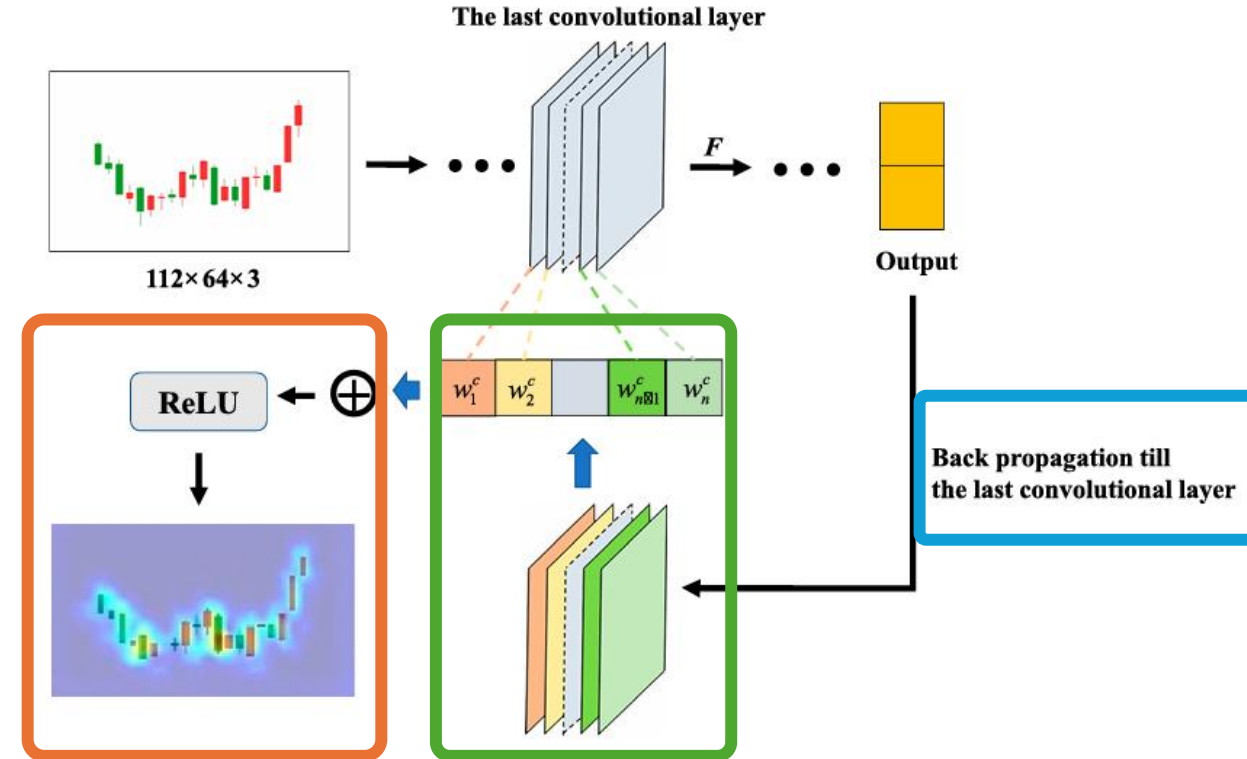


Figure 10. A schematic illustration of Grad-CAM.

5. Model Interpretability

(2) Learning technical patterns

- 세 가지 기술적 분석 패턴
 - 1) 헤드앤숄더 (Head and shoulder)
 - 2) 확장형 (Broadening)
 - 3) 삼각형 (Triangle)
- 대부분 이미지의 오른쪽을 강조
 - 최근 가격 정보에서 활성화 됨을 의미

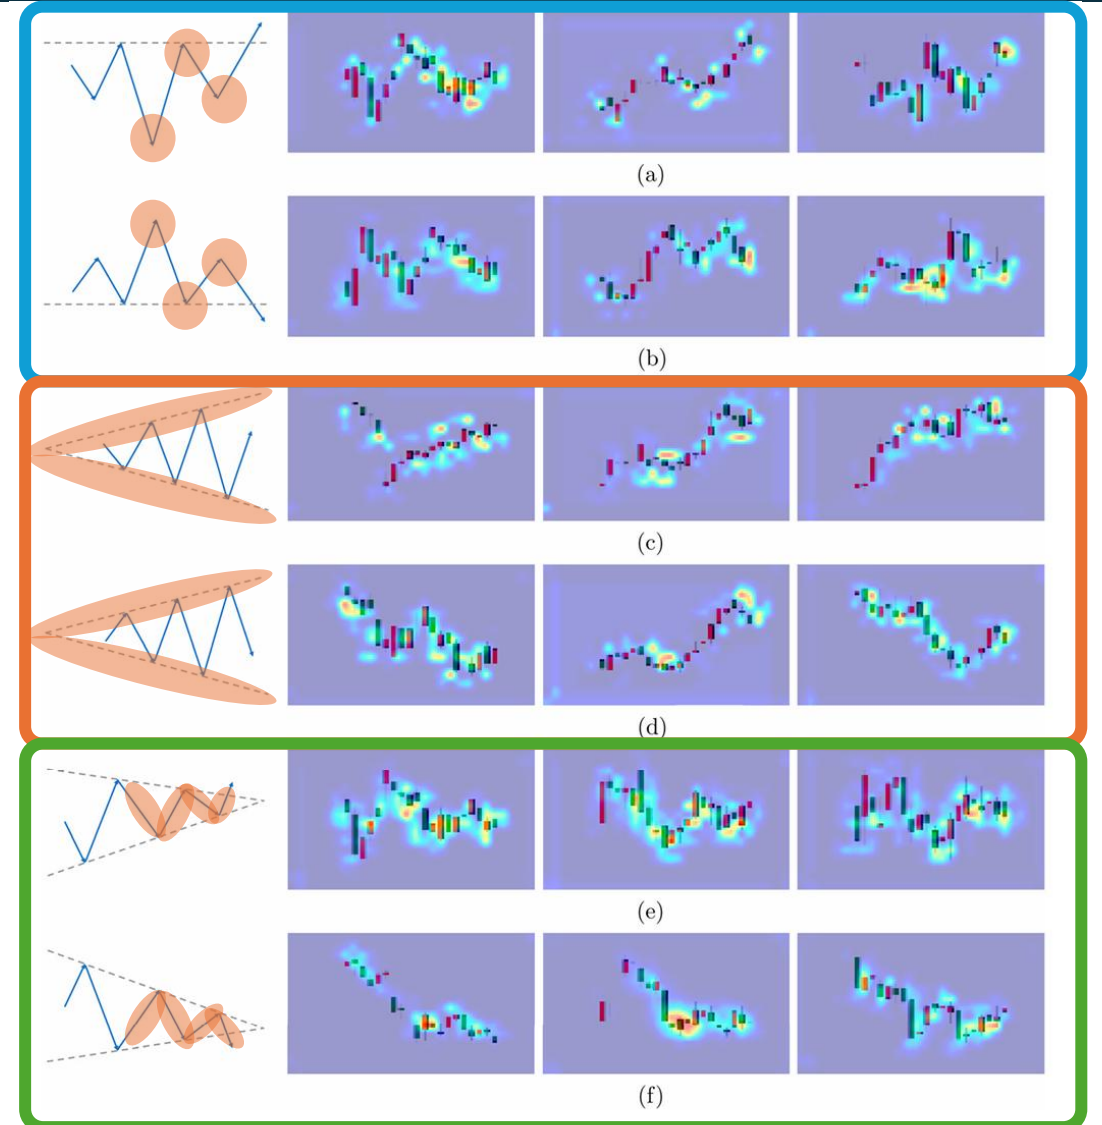


Figure 11. Toy diagrams for several technical analysis patterns, and heatmaps generated by the Grad-CAM for the last convolutional layer of CS-ACNN, based on 20-day candlesticks of 510050.SS. (a) Up: inverted head and shoulders (b) Down: head and shoulders (c) Up: broadening bottom (d) Down: broadening top (e) Up: triangle bottom (f) Down: triangle top.

5. Model Interpretability

(3) Comparison between different technical patterns and markets

Table 7. Number of candlestick charts identified with different technical patterns and the accuracy of the CS-ACNN model when using candlestick charts with these technical patterns.

Metric	All	HS	IHS	BTOP	BBOT	TTOP	TBOT
Panel A: SPY							
Number	1,463	718	707	198	84	123	178
Accuracy	0.573	0.570	0.576	0.551	0.560	0.561	0.573
Panel B: 2833.HK							
Number	858	288	312	52	49	76	44
Accuracy	0.571	0.573	0.571	0.558	0.571	0.566	0.568
Panel C: 510050.SS							
Number	826	374	402	54	72	51	50
Accuracy	0.566	0.564	0.567	0.574	0.583	0.569	0.580

- head-and-shoulders (HS)
- inverted head-and-shoulders (IHS)
- broadening tops (BTOP)
- broadening bottoms (BBOT)
- triangle tops (TTOP)
- triangle bottoms (TBOT)

- 1) 각 기술적 분석 패턴에 대해 라벨링 (20일 기간 간격) -> CS-ACNN 모델의 기술적 분석 패턴 예측 정확도 계산
- 2) 모든 패턴에 대한 모든 ETF 의 정확도는 0.55 이상
- 3) 정확도가 높은 기술적 분석 패턴은 시장마다 차이 존재 (ex. 미국, 홍콩 시장 <-> 중국 시장)
- 4) 보기 드문 기술적 분석 패턴 (BTOP, BBOT, TTOP, TBOT) 을 학습하는 능력은 중국 > 미국
 - 선진 시장 (ex. 미국) 은 효율적인 시장이므로 패턴을 학습하기가 더 어려움 (cf. 효율적 시장 이론)

6. Economic and Financial Implications

- 1) 시계열 데이터를 이미지로 변환
 - CS-ACNN 모델은 차트에 내재된 시각적 패턴과 공간적 관계를 활용하여 주식 예측 성능을 향상시킴
- 2) 기술적 분석과의 관계
 - 많은 고전적인 기술적 패턴이 CS-ACNN 모델에 의해 학습될 수 있음
- 3) 자산 가격 모델링과의 관계
 - 이미지 기반 모델을 활용하면 자산 수익 예측력을 높일 수 있음

7. Conclusion

- (1) 금융 시계열 데이터를 이미지로 변환하는 새로운 방법 제안
 - 캔들스틱 차트를 증강하여 다양한 시각적 특징을 강조하는 방법을 개발함
 - Gramian Angular Field (GAF) 방식을 사용하여 금융 시계열 데이터를 정보 손실 없이 이미지로 변환함
- (2) 딥러닝 모델 (CS-ACNN) 개발
 - 이미지에서 중요한 특징을 효과적으로 추출하는 딥러닝 모델을 제안함
 - 제안된 모델은 전통적인 시계열 기반 모델보다 주가 예측 성능이 우수하며, 수익성에서도 뛰어난 성과를 보임
- (3) 모델의 해석 가능성 확대
 - Grad-CAM 을 사용하여 모델이 학습한 시각적 패턴을 사람이 이해할 수 있도록 시각화함
 - 모델이 학습한 패턴이 전통적인 기술적 분석과 일치함을 보여주어, 모델의 경제적 해석을 뒷받침함